# Emerging Properties in Self-Supervised Vision Transformers

School of Industrial and Management Engineering, Korea University

Jong Kook, Heo





# **Contents**

Background

\* Research Purpose

Overview

\* Experimental Results

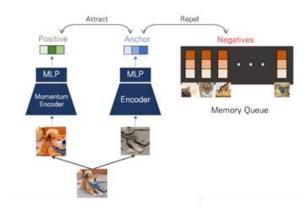
Conclusion

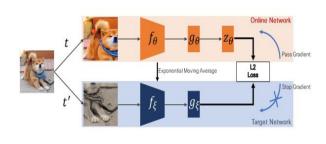
# **Background**

## Self-Supervsied Learning

- What is Self-Supervised Learning?
  - Pre-training method which exploits abundant unlabeled data with pseudo-labels defined by users, to learn good representations
    - ✓ Pretext task: 문제를 직접 정의하는 방식 ex) Rotation, Jigsaw Puzzle
    - ✓ Contrastive Learning: Noise Contrastive Estimation 방식 ex) MoCo, SimCLR, PIRL
    - ✓ Non-Constrastive Learning: Negative Sample 없이 학습하는 방식 ex) BYOL





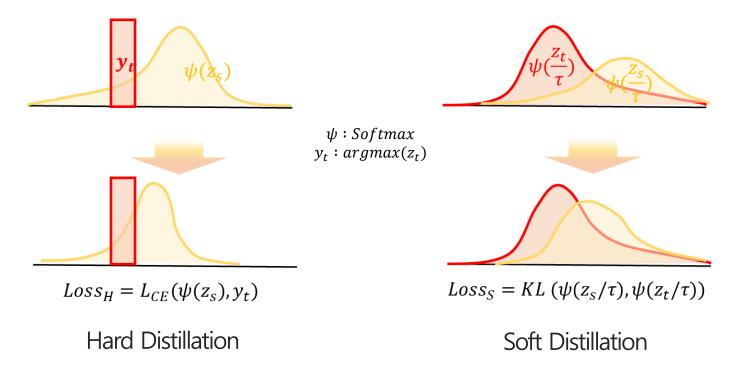


Jigsaw MoCo BYOL

# **Background**

## Knowledge Distillation

- What is Knowledge Distillation??
  - Propagating the knowledge of "teacher model" to lightweight "student model" with reducing performance degradation
    - ✓ Hard Distillation: Teacher Model 의 예측 값을 따르도록 학습
    - ✓ Soft Distillation: Teacher Model 의 예측 분포에 유사하도록 학습



# **Research Purpose**

- DINO : Distillation with no-labels
  - VIT 아키텍처에 Self-supervised Learning 을 접목
  - 2021 CVPR 에서 발표, 2021.07.07 기준 인용횟수 18회

#### **Emerging Properties in Self-Supervised Vision Transformers**

Mathilde Caron<sup>1,2</sup> Hugo Touvron<sup>1,3</sup> Ishan Misra<sup>1</sup> Hervé Jegou<sup>1</sup> Julien Mairal<sup>2</sup> Piotr Bojanowski<sup>1</sup> Armand Joulin<sup>1</sup>

<sup>1</sup> Facebook AI Research <sup>2</sup> Inria\* <sup>3</sup> Sorbonne University



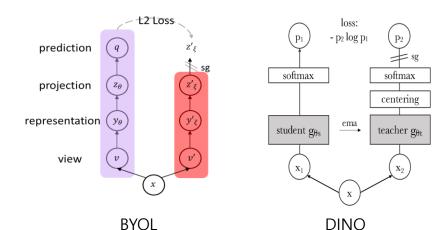
Figure 1: Self-attention from a Vision Transformer with 8 × 8 patches trained with no supervision. We look at the self-attention of the [CLS] token on the heads of the last layer. This token is not attached to any label nor supervision. These maps show that the model automatically learns class-specific features leading to unsupervised object segmentations.

# **Research Purpose**

### DINO(Self-Distillation with No-Labels)

#### Motivation

- ViT 는 기존 CNN 모델에 비해 명확한 이점을 가지지 못하였음(연산량과 데이터도 더 많이 요구되었음)
- 저자는 Transformer 가 NLP 에서 큰 성공을 거둔 주된 요소는 self-supervised pretraining 이라고 주장함
  - ✓ BERT : Masked Language Model, Next Sentence Prediction
  - ✓ GPT : Autoregressive Language Modeling
- Teacher Network 의 output 을 직접 예측하는 self-supervised Learning 방법론 제시
  - ✓ 저자는 이를 Pretrained teacher model 과 labeled data 가 필요하지 않는 knowledge distillation, 즉 DINO(Self-Distillation with No labels) 라고 명명
  - ✓ 기존의 momentum encoder(mean teacher) 방식을 쓰며 negative sample 이 필요하지 않아서 BYOL 과 매우 유사



DINO 는 BYOL과 거의 유사하나 augmentation, loss function, collapse avoiding strategy 에서 차이를 보인다.

## Interesting properties of DINO

- Self-supervised ViT features are...
  - 객체의 경계나 배경을 잘 탐지한다
    - ✓ [CLS] 토큰에 대한 last layer self-attention map 이 segmentation mask 와 매우 유사.
    - ✓ 각 self-attention head 가 서로 다른 물체나 경계를 집중적으로 잘 포착함



Fig 1: DINO 를 통해 레이블없이 모델이 자동적으로 class-specific feature 를 학습할 수 있으며, 이를 통해 unsupervised object segmentation 이 가능하다고 주장.



Fig 3: attention head 마다 다른 색깔로 [CLS] Token 에 대한 score map 계산. 이를 통해 각 head 가 서로 다른 물체나 파츠를 보고 있는 것을 알 수 있음

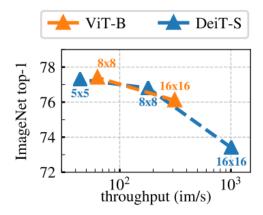
## Interesting properties of DINO

- Self-supervised ViT features are...
  - Fine-tuning 이나 hyper-parameter tuning 없이 k NN Classifier 로도 높은 성능을 보여줌
    - ✓ Multi-crop augmention 과 momentum encoder 가 있어야 k NN 성능에 크게 기여
    - ✓ 패치 사이즈가 작아질수록 throughtput 은 작아지지만 더 좋은 질의 feature 를 추출함
    - ✓ 기존 Convnet 에서도 해당 방법론을 사용할 수는 있지만 VT 계열과 궁합이 더 잘 맞음

| Method   | Mom.         | SK | MC           | Loss | Pred. | k-NN | Lin. |
|----------|--------------|----|--------------|------|-------|------|------|
| 1 DINO   | ✓            | X  | ✓            | CE   | X     | 72.8 | 76.1 |
| 2        | ×            | X  | $\checkmark$ | CE   | X     | 0.1  | 0.1  |
| 3        | $\checkmark$ | ✓  | $\checkmark$ | CE   | X     | 72.2 | 76.0 |
| 4        | $\checkmark$ | X  | X            | CE   | ×     | 67.9 | 72.5 |
| 5        | $\checkmark$ | X  | ✓            | MSE  | ×     | 52.6 | 62.4 |
| 6        | $\checkmark$ | X  | $\checkmark$ | CE   | ✓     | 71.8 | 75.6 |
| 7 BYOL   | ✓            | X  | Х            | MSE  | ✓     | 66.6 | 71.4 |
| 8 MoCov2 | $\checkmark$ | X  | X            | INCE | ×     | 62.0 | 71.6 |
| 9 SwAV   | X            | ✓  | ✓            | CE   | X     | 64.7 | 71.8 |

SK: Sinkhorn-Knopp, MC: Multi-Crop, Pred.: Predictor CE: Cross-Entropy, MSE: Mean Square Error, INCE: InfoNCE

**Table 7.** Momentum encoder, Loss, Predictor, Multi-Crop 등 방법론에 대한 ablation study



**Fig 5.** patch size 가 작아지면 throughput 은 작아지지만 성능은 좋아짐

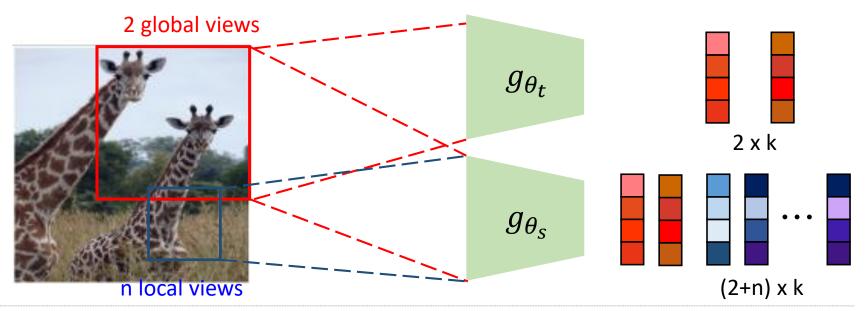
| Method         | Arch.              | Param. | im/s | Linear | k-NN |
|----------------|--------------------|--------|------|--------|------|
| Supervised     | RN50               | 23     | 1237 | 79.3   | 79.3 |
| SCLR [12]      | RN50               | 23     | 1237 | 69.1   | 60.7 |
| MoCov2 [14]    | RN50               | 23     | 1237 | 71.1   | 61.9 |
| InfoMin [64]   | RN50               | 23     | 1237 | 73.0   | 65.3 |
| BarlowT [78]   | RN50               | 23     | 1237 | 73.2   | 66.0 |
| OBoW [25]      | RN50               | 23     | 1237 | 73.8   | 61.9 |
| BYOL [28]      | RN50               | 23     | 1237 | 74.4   | 64.8 |
| DCv2 [10]      | RN50               | 23     | 1237 | 75.2   | 67.1 |
| SwAV [10]      | RN50               | 23     | 1237 | 75.3   | 65.7 |
| DINO           | RN50               | 23     | 1237 | 75.3   | 67.5 |
| Supervised     | DeiT-S             | 21     | 1007 | 79.8   | 79.8 |
| BYOL* [28]     | DeiT-S             | 21     | 1007 | 71.4   | 66.6 |
| MoCov2* [14]   | DeiT-S             | 21     | 1007 | 72.7   | 64.4 |
| SwAV* [10]     | DeiT-S             | 21     | 1007 | 73.5   | 66.3 |
| DINO           | DeiT-S             | 21     | 1007 | 77.0   | 74.5 |
| Comparison act | ross architectures |        |      |        |      |
| SCLR [12]      | RN50w4             | 375    | 117  | 76.8   | 69.3 |
| SwAV [10]      | RN50w2             | 93     | 384  | 77.3   | 67.3 |
| BYOL [28]      | RN50w2             | 93     | 384  | 77.4   | _    |
| DINO           | ViT-B/16           | 85     | 312  | 78.2   | 76.1 |
| SwAV [10]      | RN50w5             | 586    | 76   | 78.5   | 67.1 |
| BYOL [28]      | RN50w4             | 375    | 117  | 78.6   | _    |
| BYOL [28]      | RN200w2            | 250    | 123  | 79.6   | 73.9 |
| DINO           | DeiT-S/8           | 21     | 180  | 79.7   | 78.3 |
| SCLRv2 [13]    | RN152w3+SK         | 794    | 46   | 79.8   | 73.1 |
| DINO           | ViT-B/8            | 85     | 63   | 80.1   | 77.4 |

**Table 2.** backbone 에 상관없이 DINO 가 SSL 방법론보다 우수함을 보여줌. Backbone 은 ConvNet 보다 ViT 계열이 더 궁합이 좋음



#### **Process**

- Augmentation & Forward
  - SWaV(Caron et al, 2020) 의 Multi-crop 에서 차용
  - 원본 이미지에서 2개의 Global View(원본 크기의 50% ↑), n 개의 Local View(원본 크기의 50% 미만↓) 생성
  - 각 view 는 독립적으로 crop 후 augmentation 진행(ex: Global view: 224 x 224, Local view: 96 x 96)
    - ✓ Teacher network 는 2개의 Global View 를 입력으로 받음
    - ✓ Student network 는 2개의 Global View 와 n 개의 Local View 모두 입력으로 받음
    - ✓ 각 네트워크는 이후 3 층의 layer 로 구성된 MLP 와 Layer norm 을 거쳐 K dimensional vector 를 뱉음





- p<sub>2</sub> log p<sub>1</sub>

centering

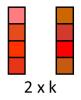
teacher got

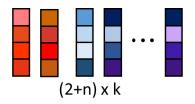
softmax

student gas

#### **Process**

- Softmax with Centering
  - Teacher Representation  $g_{\theta_t}(x)$ : Softmax + sharpening+ centering
  - Student Representation  $g_{\theta_{\mathcal{S}}}(x)$  : Softmax + sharpening
  - Centering 과 sharpening 이 model Collapse 를 방지할 수 있다고 주장

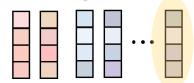


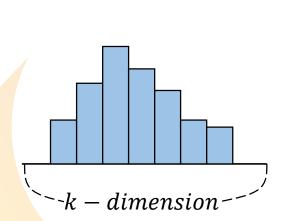


$$P_t(x)^i = Softmax \left( \frac{g_{\theta_t}(x) - C}{\tau_t} \right)_i \qquad P_s(x)^i = Softmax \left( \frac{g_{\theta_s}(x)}{\tau_s} \right)$$









 $-p_2 \log p_1$ 

centering

teacher got

softmax

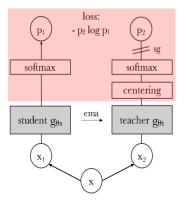
student  $g_{\theta s}$ 

Softmax over k dimension per each view

 $\tau_t$ : teacher model temperature  $\tau_s$ : student model temperature *C* : centering factor

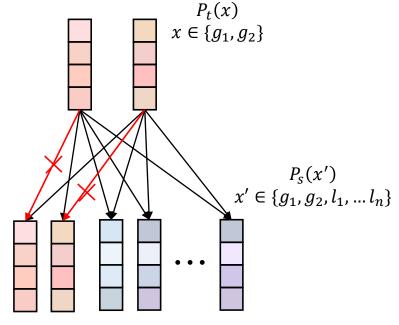
#### **Process**

- Calcualte Loss and Gradient
  - Cross Entropy Loss 를 계산(Target 값에 대해서는 stop gradient!!)
  - 같은 view 에 대해서는 loss 를 계산하지 않음



$$\min_{\theta_s} \sum_{\substack{x \in \{x_1^g, x_2^g\} \\ x' \neq x}} \sum_{\substack{\text{call views} \\ x' \neq x}} -P_t(x) log P_s(x')$$

Don't Calculate on same view pairs!!



#### **Process**

## Update

- Student Model: Teacher Model Representation 과의 KL Divergence 로 업데이트
- Teacher Model: student 모델의 가중치를 통해 모멘텀 업데이트(exponential moving avg like BYOL)
- Centering Factor: teacher output 의 batch center 를 통해 업데이트(exponential moving avg)

Student Model

$$\min_{\theta_{S}} \sum_{x \in \{x_{1}^{g}, x_{2}^{g}\}} \sum_{\substack{x' \in \text{all views} \\ x' \neq x}} -P_{t}(x) \log P_{S}(x')$$

Teacher Model

$$\theta_t \leftarrow \lambda \theta_t + (1 - \lambda)\theta_s,$$
  
$$\lambda = 0.996 \rightarrow 1(cosine\ schedule)$$

Centering factor

$$c \leftarrow mc + (1 - m)c \frac{1}{B} \sum_{i=1}^{B} g_{\theta_t}(x_i)$$

 $au_t$ : teacher model temperature  $au_s$ : student model temperature  $au_s$ : centering factor  $au_s$ : rate parameter

 $-p_2 \log p_1$ 

centering

teacher  $g_{\theta t}$ 

softmax

student gos

 $\mathbf{x}_1$ 

## Details: Centering and Sharpening

- ❖ How to avoid Collapse in DINO
  - 기존의 SSL 방법론들 Contrastive Loss, Clustering Constraints, Predictor, BatchNorm 등을 통해 Collapse 를 방지
  - DINO 에서는 momentum teacher output 에 **Centering 과 Sharpening**만 적용해도 Collapse 를 방지할 수 있다고 주장!!
    - ✓ Centering: K 차원 중 특정 차원이 dominate 하는 것을 방지하지만, uniform distribution 으로 collapse 시킬 수 있음
    - ✓ Centering 은 teacher output 에 bias term 을 붙이는 것으로 해석 될 수 있음
    - ✓ 이 bias term 은 teacher output 의 1st order batch statistic 에 영향을 받음
    - $\checkmark$  Sharpening(Temperature scaling **where 0** < au < **1)**: Centering 과 반대의 효과

$$P_t(x)^i = Softmax \left( \frac{g_{\theta_t}(x) - C}{\tau_t} \right)_i$$

Teacher output with centering and sharpening

$$c \leftarrow mc + (1 - m)c \frac{1}{B} \sum_{i=1}^{B} g_{\theta_t}(x_i)$$

C 는 teacher output 의 batch mean 으로 모멘텀 업데이트

## Details: Centering and Sharpening

- How to avoid Collapse in DINO
  - 만약 Centering 이나 Sharpening 둘 중 하나가 없다면 오른 쪽 그림과 같이 teacher 와 student 사이의 KL divergence 가 0으로 수렴(Collapse)
  - 왼쪽 그림은 Centering 이 없을 때 teacher model entropy 가 0으로, Sharpening 이 없을 때는 log K 로 가는 것을 나타내며 두 operation 이 각각 다른 Collapse 를 유발하는 것을 나타낸다.
  - 오른쪽 그림에서 둘 다 사용했을 경우, KL divergence 가 적절하게 감소하는 것을 알 수 있다.

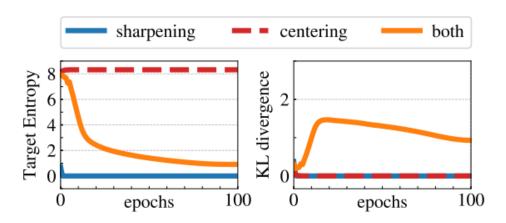


Figure 7: **Collapse study.** (**left**): evolution of the teacher's target entropy along training epochs; (**right**): evolution of KL divergence between teacher and student outputs.

#### **Total Review**

- Reminder : Pseudo Code
  - 해당 pseudo code 는 multi-crop 이 포함되지 않은 코드(multi-crop augmentation 이 들어간 pseudo code 는 논문에 기재 Ⅺ

#### Algorithm 1 DINO PyTorch pseudocode w/o multi-crop.

```
# gs, gt: student and teacher networks
# C: center (K)
# tps, tpt: student and teacher temperatures
# 1, m: network and center momentum rates
gt.params = gs.params
for x in loader: # load a minibatch x with n samples
    x1, x2 = augment(x), augment(x) # random views
    s1, s2 = gs(x1), gs(x2) # student output n-by-K
    t1, t2 = gt(x1), gt(x2) # teacher output n-by-K
    loss = H(t1, s2)/2 + H(t2, s1)/2
    loss.backward() # back-propagate
    # student, teacher and center updates
    update(gs) # SGD
    qt.params = 1*qt.params + (1-1)*qs.params
    C = m*C + (1-m)*cat([t1, t2]).mean(dim=0)
def H(t, s):
    t = t.detach() # stop gradient
    s = softmax(s / tps, dim=1)
    t = softmax((t - C) / tpt, dim=1) # center + sharpen
    return - (t * log(s)).sum(dim=1).mean()
```

# **Experimental Results**

## Other experiments

## ❖ 기타실험장표

• Image Retrieval and Copy Detection

Table 3: Image retrieval. We compare the performance in retrieval of off-the-shelf features pretrained with supervision or with DINO on ImageNet and Google Landmarks v2 (GLDv2) dataset. We report mAP on revisited Oxford and Paris. Pretraining with DINO on a landmark dataset performs particularly well. For reference, we also report the best retrieval method with off-the-shelf features [55].

|           |             |              | $\mathcal{R}Ox$ |      | $\mathcal{R}$ Par |      |
|-----------|-------------|--------------|-----------------|------|-------------------|------|
| Pretrain  | Arch.       | Pretrain     | M               | Н    | M                 | Н    |
| Sup. [55] | RN101+R-MAC | ImNet        | 49.8            | 18.5 | 74.0              | 52.1 |
| Sup.      | DeiT-S/16   | ImNet        | 33.5            | 8.9  | 63.0              | 37.2 |
| DINO      | ResNet-50   | <b>ImNet</b> | 35.4            | 11.1 | 55.9              | 27.5 |
| DINO      | DeiT-S/16   | <b>ImNet</b> | 41.8            | 13.7 | 63.1              | 34.4 |
| DINO      | DeiT-S/16   | GLDv2        | 51.5            | 24.3 | <b>75.3</b>       | 51.6 |

Table 4: **Copy detection.** We report the mAP performance in copy detection on Copydays "strong" subset [20]. For reference, we also report the performance of the multigrain model [5], trained specifically for particular object retrieval.

| Method                           | Arch.                  | Dim.         | Resolution                           | mAP          |
|----------------------------------|------------------------|--------------|--------------------------------------|--------------|
| Multigrain [5]<br>Multigrain [5] | ResNet-50<br>ResNet-50 | 2048<br>2048 | 224 <sup>2</sup><br>largest side 800 | 75.1<br>82.5 |
| Supervised [66]                  | ViT-B/16               | 1536         | $224^{2}$                            | 76.4         |
| DINO                             | ViT-B/16               | 1536         | $224^{2}$                            | 81.7         |
| DINO                             | ViT-B/8                | 1536         | $320^{2}$                            | 85.5         |

# **Experimental Results**

## Other experiments

- ❖ 기타실험장표
  - Fine tuning

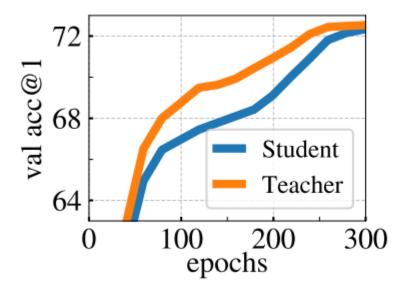
Table 6: Transfer learning by finetuning pretrained models on different datasets. We report top-1 accuracy. Self-supervised pretraining with DINO transfers better than supervised pretraining.

|           | Cifar <sub>10</sub> | Cifar <sub>100</sub> | INat <sub>18</sub> | INat <sub>19</sub> | Flwrs | Cars | INet |
|-----------|---------------------|----------------------|--------------------|--------------------|-------|------|------|
| DeiT-S/16 |                     |                      |                    |                    |       |      |      |
| Sup. [66] | 99.0                | 89.5                 | 70.7               | 76.6               | 98.2  | 92.1 | 79.9 |
| DINO      | 99.0                | 90.5                 | 72.0               | <b>78.2</b>        | 98.5  | 93.0 | 81.5 |
| ViT-B/16  |                     |                      |                    |                    |       |      |      |
| Sup. [66] | 99.0                | 90.8                 | 73.2               | 77.7               | 98.4  | 92.1 | 81.8 |
| DINO      | 99.1                | 91.7                 | 72.6               | <b>78.6</b>        | 98.8  | 93.0 | 82.8 |

# **Experimental Results**

## Other experiments

- ❖ 기타실험장표
  - Update Options



| Top-1 |
|-------|
| 0.1   |
| 0.1   |
| 66.6  |
| 72.8  |
|       |

## **Conclusion**

- ❖ 단순히 ViT 에 SSL을 적용한 것에 의의를 둔것이 해당 방법론을 적용 했을 때, Supervised ViT 나 ConvNet 에서 나타나지 않았던 현상을 발견한 것이 큰 의미가 있음
  - ✓ DINO 를 적용한 ViT 는 객체의 경계나 배경을 매우 잘 탐지하며, 이러한 특징들은 linear layer fine-tuning 없이 k NN classifier 로도 높은 성능을 나타냄
  - ✓ Segmentation 등의 다른 task를 주지 않고 positive sample 로 representation learning 만을 했을 뿐인데 결과가 기존 segmentation 방법론에 근접
  - ✓ 논문에서도 언급하듯이, Computer vision 에서도 GPT 나 BERT 같이 다른 분야의 태스크도 수행가능한 pre-trained model 이 더욱 발전되리라 기대됨

## ❖ 엄청나게 많은 실험을 진행

- ✓ 방법론의 타당성을 위해 Momentum Encoder, Loss 등 옵션에 대해 모두 ablation study 를 진행
- ✓ Predictor 나 Negative Sample 없이도 단순 연산만으로 Collapse 를 방지하였는 것은 굉장히 큰 의미가 있다고 봄
- ✓ 특히 Sharpening 과 Centering 가 서로 상충된 효과를 내지만 둘 중 하나가 없으면 서로 다른 방향으로 collapse 가 진행된다는 것을 보여준 것이 재밌었음

# Reference

- Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021).
  Emerging properties in self-supervised vision transformers. arXiv preprint arXiv:2104.14294.
- Noroozi, M., & Favaro, P. (2016, October). Unsupervised learning of visual representations by solving jigsaw puzzles. In *European conference on computer vision* (pp. 69-84). Springer, Cham.
- http://dmqa.korea.ac.kr/activity/seminar/310
  - ✓ Dive into BYOL